

STATISTICAL HEALTH AUDIT REPOSITORI OPEN-SOURCE *PANDAS-DEV/PANDAS*

Laporan Statistical Health Final Project Mata Kuliah Statistika dan Probabilitas



Disusun Oleh Kelompok 11:

Nama	NIM
Adam Raysa Rahman	1519625009
Elpa Padila	1519625020
Natasya Nur Afriani	1519625022
Riyadh Fadhillah	1519625030
Daffa Alfaridzi	1519625054

Dosen Pengampu:

Muhammad Ridho Kurniawan Pratama, S. Kom, M.T.I.

**SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK UNIVERSITAS
NEGERI JAKARTA
TAHUN 2026**

DAFTAR ISI

DAFTAR ISI.....	1
Penataan Peran.....	1
1. Executive Summary.....	1
1.1 Temuan Utama.....	1
2. Data Overview.....	2
2.1 Sumber Data.....	2
3.2 Variabel Utama.....	2
3.3 Keterbatasan Data.....	2
3. Estimasi Parameter.....	3
3.1 RQ1 - MLE Bernoulli & Estimasi Bayesian.....	3
• Langkah Derivasi MLE Bernoulli.....	3
• Estimasi Bayesian (Beta Posterior).....	3
3.2 RQ2 — MLE Poisson.....	3
4. Confidence Interval dan Credible Interval.....	4
4.1 Confidence Interval Bernoulli (RQ1).....	4
4.2 Credible Interval Bayesian (RQ1).....	4
4.3 Confidence Interval Poisson (RQ2).....	4
5. Pengujian Hipotesis.....	5
6. Analisis Komputasi.....	6
6.1 Simulasi Monte Carlo — Probabilitas Extreme Load.....	6
6.2 Bloom Filter - Optimasi Deteksi Duplikasi Issue.....	6
6.3 MCMC Knapsack — Optimasi Prioritas Bug Mingguan.....	7
7. Rekomendasi.....	8
Rekomendasi 1 — Tetapkan SLA 7 Hari untuk Bug Critical.....	8
Rekomendasi 2 — Implementasikan Alert Otomatis Berbasis CI Poisson.....	8
Rekomendasi 3 — Integrasikan Bloom Filter pada Alur Pembuatan Issue.....	8
Rekomendasi 4 — Terapkan MCMC Triaging untuk Sprint Planning.....	8

Penataan Peran / Role

Peran	Nama	NIM
Data Engineer	Natasya Nur Afriyani	1519625022
Estimation Analyst	Elpa Padila	1519625020
Inference Analyst	Riyadh Fadilah	1519625030
Hypothesis Analyst	Daffa Alfaridzi	1519625054
Computation Analyst	Adam Raysa Rahman	1519625009

1. Executive Summary

Laporan ini menyajikan audit statistik terhadap repositori pandas-dev/pandas, salah satu library Python paling aktif dengan lebih dari 1.300 closed issues dan 1.100 merged pull requests. Audit dilakukan dengan pendekatan estimasi parameter, inferensi statistik, pengujian hipotesis, dan analisis komputasi untuk menjawab tiga pertanyaan riset utama mengenai kesehatan dan efisiensi pengelolaan repositori.

1.1 Temuan Utama

1. Responsivitas tinggi terhadap bug: Lebih dari separuh bug (53,34%) berhasil diselesaikan dalam 7 hari atau kurang, menunjukkan tim inti sangat responsif.
2. Laju penyelesaian stabil 7,5 bug/minggu: Estimasi Poisson MLE menghasilkan $\lambda = 7,4808$ bug/minggu yang dapat dijadikan baseline perencanaan sprint.
3. Tidak ada perubahan signifikan dari baseline: Uji Z satu sampel ($z = -0,0001$, $p = 0,9999$) gagal menolak H_0 , mengindikasikan proses pengelolaan bug berjalan stabil.
4. Risiko extreme load sangat kecil: Simulasi Monte Carlo (50.000 iterasi) menunjukkan probabilitas >15 bug masuk dalam satu minggu hanya 0,45%.
5. Bloom Filter efektif menekan duplikat: FPR empiris 1,9% selaras dengan prediksi teoritis, membuktikan kelayakan implementasi pada skala repositori nyata.

2. Data Overview

2.1 Sumber Data

Data dikumpulkan dari GitHub REST API v3 pada repositori pandas-dev/pandas (<https://github.com/pandas-dev/pandas>) menggunakan pendekatan time-based pagination. Pengambilan data dilakukan pada Mei 2026.

Kategori Data	Jumlah Record	Keterangan
Closed Issues	1.311	Issue berstatus closed
Merged Pull Requests	1.112	PR yang telah di-merge
Total setelah cleaning	2.423	Setelah deduplication
Subset bug (is_bug=1)	778	Issue berlabel 'bug'
Periode pengamatan	104 minggu	±2 tahun data historis

3.2 Variabel Utama

Variabel	Tipe	Deskripsi
duration_days	Numerik kontinu	Selisih closed_at dan created_at (hari)
is_bug	Biner (0/1)	1 jika issue berlabel 'bug'
quick_resolve	Biner (0/1)	1 jika duration_days ≤ 7
bugs_per_week	Cacah	Jumlah bug diselesaikan per minggu
type	Kategorikal	'issue' atau 'pull_request'

3.3 Keterbatasan Data

1. GitHub API membatasi 5.000 request/jam; data diambil dengan rate limiting 1,5 detik/halaman.
2. Label 'bug' tidak selalu konsisten diterapkan, sehingga variabel is_bug mungkin mengandung label noise.
3. Outlier dengan durasi >365 hari sengaja tidak dihapus karena relevan untuk analisis RQ3.
4. Pull request yang di-close tanpa merge tidak dimasukkan dalam analisis.

3. Estimasi Parameter

Estimasi parameter dilakukan menggunakan metode Maximum Likelihood Estimation (MLE) dan pendekatan Bayesian untuk menjawab RQ1 dan RQ2. Semua formula mengacu pada Tsun (2020).

3.1 RQ1 - MLE Bernoulli & Estimasi Bayesian

Variabel acak Bernoulli $X = 1$ jika sebuah bug diselesaikan dalam 7 hari atau kurang. Dari 778 sampel bug, diperoleh $k = 415$ sukses dan $m = 363$ gagal.

- **Langkah Derivasi MLE Bernoulli**

Fungsi likelihood Bernoulli (Tsun, 2020, hal. 254):

$$L(\theta) = \theta^k * (1 - \theta)^{(n-k)}$$

Mengambil log dan menyamakan turunan pertama terhadap θ dengan nol:

$$d/d(\theta) [\ln L(\theta)] = k/\theta - (n-k)/(1-\theta) = 0$$

Solusinya menghasilkan estimasi MLE:

$$\theta_{\text{hat}} = k / n = 415 / 778 = 0,5334$$

Kesimpulan RQ1: Probabilitas sebuah bug baru di repositori Pandas diselesaikan dalam 7 hari atau kurang adalah **53,34%**.

- **Estimasi Bayesian (Beta Posterior)**

Menggunakan prior seragam Beta(1,1), parameter posterior dihitung sebagai (Tsun, 2020, hal. 269):

$$\alpha = k + 1 = 416 \quad \beta = m + 1 = 364$$

Parameter	Nilai	Formula
Alpha (a)	416	$k + 1 = 415 + 1$
Beta (b)	364	$m + 1 = 363 + 1$
Mode	0,5332	$(a - 1) / (a + b - 2)$
Mean	0,5333	$a / (a + b)$

3.2 RQ2 — MLE Poisson

Variabel acak Poisson X = jumlah bug diselesaikan per minggu, diobservasi selama 104 minggu. MLE Poisson menghasilkan (Tsun, 2020, hal. 254):

$$\lambda_{\text{hat}} = (1/n) * \sum(x_i) = \text{total_bug} / 104 = 7,4808 \text{ bug/minggu}$$

Kurva log-likelihood Poisson berbentuk konkaf dengan puncak tepat di $\lambda = 7,4808$, membuktikan secara visual bahwa nilai ini adalah estimasi parameter yang paling optimal berdasarkan data.

Kesimpulan RQ2: Secara historis, tim Pandas menyelesaikan rata-rata 7 hingga 8 bug setiap minggu.

4. Confidence Interval dan Credible Interval

Interval kepercayaan dibangun menggunakan formula dasar (Tsun, 2020, hal. 300):

$$CI = \text{theta_hat} \pm z_{(a/2)} * \text{sigma} / \text{sqrt}(n)$$

4.1 Confidence Interval Bernoulli (RQ1)

Dengan $\text{theta_hat} = 0,5334$, $\text{sigma} = \sqrt{0,5334 * 0,4666} = 0,4988$, $n = 778$, dan $z_{(0,025)} = 1,96$:

$$CI_{95\%} = [0,498 ; 0,568]$$

Interpretasi frekuentis: Jika prosedur pengambilan sampel dan pembangunan interval ini diulang berkali-kali dalam kondisi yang sama, maka 95% dari seluruh interval yang dihasilkan akan memuat nilai parameter θ yang sebenarnya. Interval ini bukan pernyataan probabilistik langsung tentang θ .

4.2 Credible Interval Bayesian (RQ1)

Menggunakan distribusi posterior $\text{Beta}(416, 364)$, credible interval 95% diperoleh dari persentil 2,5% dan 97,5% distribusi beta posterior:

$$\text{Credible Interval}_{95\%} = [0,498 ; 0,568]$$

Interpretasi Bayesian: Mengingat seluruh data yang telah diamati, terdapat probabilitas 95% bahwa nilai θ yang sebenarnya berada di antara 0,498 dan 0,568. Ini adalah pernyataan probabilistik langsung yang valid dalam kerangka Bayesian, berbeda dari interpretasi frekuentis confidence interval di atas.

Kedua interval menghasilkan batas yang hampir identik karena prior seragam $\text{Beta}(1,1)$ bersifat non-informatif sehingga posterior didominasi oleh data.

4.3 Confidence Interval Poisson (RQ2)

Dengan $\text{lambda_hat} = 7,4808$, $\text{sigma} = \sqrt{\text{lambda_hat}} = 2,7351$, $n = 104$:

$$CI_{95\%} (\text{Poisson}) = [6,955 ; 8,006] \text{ bug/minggu}$$

Interpretasi: Jika prosedur ini diulang dengan sampel berbeda, 95% dari interval yang dibangun akan memuat laju penyelesaian bug yang sebenarnya. Maintainer dapat berkeyakinan bahwa laju aktual berada di kisaran 7 hingga 8 bug per minggu.

Interval	Tipe	Batas Bawah	Batas Atas	Lebar
CI Bernoulli (θ)	Frequentist	0,498	0,568	0,070
Credible Interval	Bayesian	0,498	0,568	0,070
CI Poisson (λ)	Frequentist	6,955	8,006	1,051

5. Pengujian Hipotesis

Pengujian hipotesis dilakukan untuk menjawab RQ2: apakah rata-rata penyelesaian bug mingguan berbeda secara signifikan dari nilai yang diasumsikan? Prosedur mengikuti 6 langkah formal sesuai Tsun (2020, hal. 306).

Uji Z Satu Sampel - Laju Penyelesaian Bug Mingguan

- **Langkah 1: Perumusan Hipotesis**

$H_0 : \mu = 7,4808$ (rata-rata penyelesaian bug per minggu sama dengan nilai historis)

$H_a : \mu \neq 7,4808$ (rata-rata berbeda dari nilai historis)

- **Langkah 2: Pemilihan Uji Statistik**

Uji Z satu sampel dipilih karena (1) ukuran sampel besar ($n = 104 \geq 30$), (2) distribusi sampel mendekati normal berdasarkan Central Limit Theorem, dan (3) simpangan baku populasi diestimasi dari data.

- **Langkah 3: Penentuan Tingkat Signifikansi**

Tingkat signifikansi $\alpha = 0,05$, uji dua sisi (two-tailed). Daerah kritis: $|Z| > 1,96$.

- **Langkah 4: Perhitungan Statistik Uji**

Formula Z satu sampel (Tsun, 2020, hal. 306):

$$Z = (\bar{x} - \mu_0) / (\sigma / \sqrt{n})$$

Dengan $\bar{x} = 7,4808$, $\mu_0 = 7,4808$, $\sigma = 5,0677$, $n = 104$:

$$Z = (7,4808 - 7,4808) / (5,0677 / \sqrt{104}) = -0,0001$$

- **Langkah 5: Perhitungan P-Value**

$$p\text{-value} = 2 * P(Z > |-0,0001|) = 0,9999$$

- **Langkah 6: Keputusan dan Kesimpulan**

Karena $p\text{-value} (0,9999) > \alpha (0,05)$, dan $|Z| = 0,0001 < 1,96$:

Keputusan: Fail to reject H_0 .

Tidak terdapat cukup bukti statistik untuk menyimpulkan bahwa rata-rata penyelesaian bug mingguan berbeda dari nilai baseline. Hal ini mengindikasikan stabilitas dan konsistensi proses pengelolaan bug di repositori Pandas.

Parameter Uji	Nilai
Rata-rata sampel ($\bar{x}$)	7,4808 bug/minggu
Nilai hipotesis (μ_0)	7,4808 bug/minggu
Jumlah minggu (n)	104
Std. deviasi (σ)	5,0677
Z-statistik	-0,0001
P-value	0,9999
Tingkat signifikansi (α)	0,05

6. Analisis Komputasi

Analisis komputasi menggunakan tiga teknik untuk menjawab RQ3 dan mendukung efisiensi pengelolaan repositori: simulasi Monte Carlo, Bloom Filter, dan MCMC Knapsack. Seluruh implementasi mengimpor fungsi dari `src/simulation.py`.

6.1 Simulasi Monte Carlo — Probabilitas Extreme Load

Pertanyaan: Seberapa besar kemungkinan repositori Pandas mengalami bottleneck (lebih dari 15 bug masuk dalam satu minggu) berdasarkan laju historis $\lambda = 7,4808$?

Justifikasi metode: Distribusi durasi penyelesaian issue bersifat right-skewed dan tidak mengikuti distribusi parametrik standar secara ketat. Monte Carlo memungkinkan estimasi probabilitas empiris langsung dari pola historis tanpa asumsi distribusi, memberikan hasil yang lebih robust untuk data dengan outlier ekstrem.

Metodologi: Fungsi `estimate_probability` menjalankan 50.000 iterasi. Setiap iterasi mensimulasikan jumlah bug masuk per minggu menggunakan distribusi Poisson dengan λ

$= 7,4808$, lalu memeriksa apakah nilainya melebihi 15.

Parameter Simulasi	Nilai
Jumlah iterasi (<code>n_trials</code>)	50.000
Lambda historis	7,4808 bug/minggu
Threshold extreme load	> 15 bug/minggu
P(extreme load)	0,0045 (0,45%)

Interpretasi: Probabilitas sistem mengalami lonjakan bug di atas 15 kasus dalam satu minggu hanyalah 0,45%. Rata-rata laju yang stabil (7,48) menunjukkan maintainer tidak perlu melakukan penjadwalan on-call darurat untuk mengantisipasi anomali traffic mingguan. Kondisi extreme load sangat jarang secara statistik.

6.2 Bloom Filter - Optimasi Deteksi Duplikasi Issue

Justifikasi metode: Repositori aktif seperti Pandas menerima ribuan issue. Bloom Filter menyediakan pengecekan keanggotaan dengan kompleksitas $O(k)$ yang jauh lebih efisien dari pencarian linear $O(n)$, dengan trade-off false positive yang dapat dikontrol secara matematis.

Formula FPR (Tsun, 2020, hal. 329):

$$FPR = (1 - (1 - 1/m)^n)^k$$

di mana m = ukuran bit array, n = jumlah elemen, k = jumlah fungsi hash.

Parameter	Nilai	Keterangan
k (fungsi hash)	3	Jumlah fungsi hash MD5
m (ukuran bit)	1.000	Ukuran bit array
n (items)	100	Issue yang dimasukkan

FPR Teoritis	0,0009	Formula Tsun hal. 329
FPR Empiris	0,0190	Diukur dari 1.000 item baru

Interpretasi: Bloom Filter terbukti efektif. FPR empiris (~1,9%) sedikit lebih tinggi dari teoritis (0,09%) karena ukuran m yang kecil (1.000 bit) relatif terhadap jumlah item. Dalam skenario produksi dengan $m = 100.000$ bit dan $k = 5$, FPR dapat ditekan di bawah 0,002%. Bloom Filter memiliki nol false negative, artinya jika sistem menyatakan issue belum pernah ada, kepastiannya mutlak.

6.3 MCMC Knapsack — Optimasi Prioritas Bug Mingguan

Justifikasi metode: Maintainer menghadapi batasan kapasitas kerja (40 jam/minggu) namun harus memilih bug mana yang diprioritaskan berdasarkan keparahan dan estimasi waktu penyelesaian. Ini adalah masalah Knapsack 0/1 yang bersifat NP-hard (2^{15} kombinasi = 32.768 kemungkinan). MCMC dengan algoritma Metropolis memberikan solusi near-optimal dalam waktu yang terkontrol.

Parameter MCMC	Nilai
Kapasitas kerja	40 jam/minggu
Jumlah bug dalam backlog	15 bug
Jumlah iterasi MCMC	50.000
Total waktu digunakan	40 jam
Total skor severity	464 poin

Hasil prioritas optimal: MCMC merekomendasikan 8 dari 15 bug untuk dikerjakan dalam satu minggu, dengan total 40 jam kerja dan skor severity 464

Bug ID	Estimasi Waktu	Skor Severity
Bug-0	11 jam	73
Bug-2	9 jam	23
Bug-3	3 jam	81
Bug-5	2 jam	42
Bug-7	3 jam	84
Bug-8	7 jam	94
Bug-9	3 jam	34
Bug-13	2 jam	33

Interpretasi: Metode MCMC berhasil menemukan skema prioritas near-optimal tanpa menghitung semua 32.768 kombinasi secara exhaustive. Pendekatan random walk dengan stochastic acceptance terbukti andal menghindari local optima. Maintainer dapat mengadopsi output ini sebagai panduan triaging beban kerja mingguan yang berbasis data dan objektif.

7. Rekomendasi

Berdasarkan seluruh temuan statistik di atas, berikut rekomendasi spesifik yang ditujukan kepada maintainer repositori pandas-dev/pandas.

Rekomendasi 1 — Tetapkan SLA 7 Hari untuk Bug Critical

Temuan menunjukkan 53,34% bug diselesaikan dalam 7 hari atau kurang dengan Confidence Interval 95% [0,498; 0,568]. Maintainer disarankan secara resmi mengadopsi 7 hari sebagai target Service Level Agreement untuk bug critical dan memantau nilai theta secara bulanan. Jika theta turun di bawah 0,498 (batas bawah CI) selama dua bulan berturut-turut, hal ini dapat dijadikan sinyal untuk meninjau kapasitas tim review.

Rekomendasi 2 — Implementasikan Alert Otomatis Berbasis CI Poisson

Dengan laju baseline $\lambda = 7,48$ bug/minggu dan CI [6,955; 8,006], maintainer dapat mengimplementasikan sistem alerting di GitHub Actions: jika penyelesaian bug per minggu turun di bawah 6,955 atau melebihi 8,006 selama tiga minggu berturut-turut, tim harus melakukan review kapasitas atau triase menyeluruh. Ini memberikan early warning system berbasis data statistik yang objektif dan tidak bergantung pada penilaian subjektif.

Rekomendasi 3 — Integrasikan Bloom Filter pada Alur Pembuatan Issue

Untuk mengurangi beban review issue duplikat, disarankan mengintegrasikan Bloom Filter ke dalam alur pembuatan issue baru melalui GitHub Actions bot. Bot ini dapat secara otomatis memperingatkan pelapor jika issue serupa kemungkinan besar sudah pernah dilaporkan sebelumnya. Dengan konfigurasi $m = 100.000$ dan $k = 5$, FPR dapat ditekan di bawah 0,002% sehingga hampir tidak ada false alarm yang mengganggu pelapor issue yang sah.

Rekomendasi 4 — Terapkan MCMC Triaging untuk Sprint Planning

Dengan kapasitas maintainer yang terbatas, MCMC Knapsack dapat diadopsi sebagai alat bantu objektif dalam sesi sprint planning mingguan. Input berupa estimasi waktu penyelesaian dan skor severity setiap bug, output berupa kombinasi bug yang memaksimalkan total severity yang dapat diselesaikan dalam batasan jam kerja. Pendekatan ini menggantikan triaging berbasis intuisi dengan keputusan berbasis data yang dapat diaudit dan direproduksi.